AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih
Özgür Kerem Öncel	Gece 4/B · No: 225541072	09.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

AMR: QR/istasyon kamerası → ürün-raf doğrulama, rota/öncelik → hedef raf, hız profili → TARQAN

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   YZ sonucu tek başına sevkiyat kararı olmaz. Bağımsız ikinci kontrol: toplamada barkod okutma + WMS sipariş–ürün–adet eşleştirmesi; paketlemede insan onayı. %99,99 doğruluk iddiası bile ~10.000 toplamada 1 hata demektir, ikinci kontrol kaldırılmaz. YZ hatası hareket emniyetini etkileyemez: durdurma kararı safety yolundadır. KÖR NOKTA: YZ'nin robotun hangi kararında kullanıldığı yayımlanmamış.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Fark etme: okunan QR kimliği ile IMU + enkoder konum tahmini karşılaştırılır (10 mm nominal sapmanın üstü şüpheli); beklenen sonraki düğümle uyuşmazlık; donmuş/tekrar eden kare; istasyon kamerasında barkodla çelişen sonuç. Ne yapılır: robot yavaşlar ve güvenli durur, düğüm/etiket işaretlenir, filo yönetimine ve vardiya sorumlusuna alarm; insan doğrulaması gelene kadar o noktadan otomatik geçiş yok.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik tahminle değil, doğrulama verisiyle ve kabul edilebilir hata oranına göre belirlenip kayda geçer (örnek başlangıç %95 — tasarım varsayımı). Eşik altında: ürün doğrulamada insana sor (istasyon ekranında onay); konum/rota kararında deterministik fallback (QR + IMU + enkoder, sabit rota); aynı noktada tekrar eden düşük güvende robot dur + bakım kaydı.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Barkod + WMS eşleştirmesiyle ikinci kontrol, paketlemede insan onayı; hareket emniyetine etkisi yok — Human override + fail-safe (emniyet YZ dışında)
Girdi manipüle edildi	QR–IMU–enkoder tutarlılık kontrolü; şüphede yavaşla, dur, alarm ver, insan doğrulamasını bekle — Monitoring + fail-safe
Confidence düştü	Validasyonla belirlenen eşiğin altında insana sor veya deterministik navigasyona geç; tekrar ederse dur — Confidence threshold + fallback + human override

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.